Università degli Studi di Salerno
Corso di Machine Learning

Sepsis Analysis and Triage
Report di Progetto
Data 16/03/2026

Docenti:
Prof.ssa Caruccio Loredana
Prof. Polese Giuseppe

Autore:
Sinopoli Mario - 0512119113

Indice

1 - Scenario/Problema/Task analizzato..... 3
Scenario e Contesto Applicativo..... 3
Definizione del Problema..... 3
Obiettivi del Progetto..... 4
Descrizione Task Machine Learning..... 4
1. Raccolta e comprensione dei dati..... 4
2. Analisi esplorativa dei dati (EDA)..... 4
3. Preprocessing dei dati..... 5
4. Addestramento dei modelli..... 5
5. Valutazione delle prestazioni..... 5
Rilevanza del Problema..... 6
2 - Dataset utilizzato e caratteristiche..... 6
Origine del dataset..... 6
Struttura generale del dataset..... 6
Tipologie di variabili..... 7
1. Parametri vitali..... 7
2. Risultati di esami di laboratorio..... 7
3. Variabili cliniche aggiuntive..... 8
4. Variabile target..... 8
Dimensioni del dataset..... 8
Qualità dei dati e problematiche..... 8

Ruolo del dataset nel progetto..... 9
3- Issue analizzate, soluzioni proposte e scelte di progettazione..... 9
Squilibrio tra le classi (Class Imbalance).....9
Presenza di valori mancanti nei dati clinici..... 10
Complessità del problema clinico..... 11
Scelta dei modelli di Machine Learning..... 11
Naive Bayes..... 11
Decision Tree..... 12
Motivazioni della scelta e sintesi delle scelte progettuali..... 12
4 - Analisi delle prestazioni, risultati e interpretazione.....13
Metodologia di valutazione..... 13
Metriche di valutazione.....14
Accuracy..... 14
Precision..... 14
Recall..... 15
F1-Score..... 15
Risultati numerici..... 16
Livello 1 - Classificazione Binaria:..... 16
Livello 2 - Classificazione Multiclasse:.....18
Analisi dei risultati..... 20
5 - Considerazioni finali..... 21
Risultati ed Interpretabilità.....21
Conclusione e Possibili sviluppi..... 22

1 - Scenario/Problema/Task analizzato

Scenario e Contesto Applicativo

La sepsi rappresenta una delle principali cause di mortalità negli ospedali di tutto il mondo. Si tratta di una condizione clinica grave che deriva da una risposta eccessiva e disfunzionale dell'organismo a un'infezione. Questa risposta può portare rapidamente a danni ai tessuti, insufficienza multiorgano e, nei casi più gravi, alla morte del paziente.
Uno degli aspetti più critici nella gestione della sepsi è la **tempestività della diagnosi**. Numerosi studi clinici dimostrano infatti che un trattamento precoce può ridurre significativamente il rischio di complicazioni e migliorare la probabilità di sopravvivenza del paziente. Tuttavia l'identificazione precoce della sepsi è spesso complessa, poiché i sintomi iniziali possono essere **generici e simili a quelli di altre condizioni cliniche meno gravi**.

Nel contesto ospedaliero moderno vengono raccolte grandi quantità di dati clinici relativi ai pazienti, tra cui:

- Parametri vitali (frequenza cardiaca, pressione sanguigna, temperatura, ecc.).
- Risultati di esami di laboratorio.
- Informazioni demografiche.
- Storico clinico e diagnosi precedenti.

Questa grande disponibilità di dati rende possibile l'utilizzo di tecniche di **Machine Learning** per supportare il personale medico nell'identificazione precoce dei pazienti a rischio di sepsi.
L'idea alla base di questo progetto è quella di sfruttare questi dati clinici per costruire un modello predittivo in grado di **identificare automaticamente pattern nei dati che possano indicare l'insorgenza della sepsi**.

Definizione del Problema

Il problema affrontato in questo progetto può essere formulato come un **problema di classificazione supervisionata**.
Dato un insieme di osservazioni cliniche relative ai pazienti (feature), l'obiettivo è costruire un modello che sia in grado di predire se un paziente svilupperà o meno una condizione di sepsi. Formalmente:

- **Input:** un insieme di variabili cliniche e demografiche del paziente
- **Output:** una variabile binaria che indica la presenza o l'assenza di sepsi

Il modello deve quindi apprendere una funzione che, a partire dai dati disponibili, possa stimare la probabilità che un paziente appartenga alla classe "sepsi".

Questo tipo di problema è particolarmente rilevante in ambito sanitario perché consente di sviluppare **sistemi di supporto decisionale clinico (Clinical Decision Support Systems)**. Tali sistemi non sostituiscono il giudizio medico, ma possono fornire indicazioni utili per individuare precocemente situazioni a rischio.

Obiettivi del Progetto

L'obiettivo principale del progetto è sviluppare una pipeline di machine learning che permetta di:

1. **Analizzare il dataset clinico** attraverso tecniche di esplorazione dei dati (Exploratory Data Analysis – EDA).
2. **Preprocessare i dati**, gestendo eventuali valori mancanti, anomalie o variabili non informative.
3. **Addestrare modelli di classificazione** in grado di distinguere tra pazienti con sepsi e pazienti senza sepsi.
4. **Valutare le prestazioni dei modelli** utilizzando metriche appropriate per problemi di classificazione binaria.
5. **Confrontare diversi approcci di modellazione**, al fine di individuare il modello con le migliori prestazioni predittive.

Inoltre, particolare attenzione viene posta alla **interpretabilità dei risultati**, aspetto fondamentale quando si lavora con dati clinici e applicazioni potenzialmente utilizzabili in ambito sanitario.

Descrizione Task Machine Learning

Il task affrontato può essere descritto come un problema di **binary classification**, nel quale ogni osservazione del dataset rappresenta un paziente o una registrazione clinica associata a un paziente.
Le principali fasi del task sono:

1. Raccolta e comprensione dei dati

Il dataset contiene una serie di variabili cliniche che descrivono lo stato fisiologico dei pazienti. Queste variabili possono includere parametri vitali, risultati di esami di laboratorio o altri indicatori clinici rilevanti.
La prima fase del lavoro consiste nella **comprensione della struttura del dataset**, dell'interpretazione delle variabili e della distribuzione delle osservazioni tra le classi.

2. Analisi esplorativa dei dati (EDA)

Attraverso tecniche di Exploratory Data Analysis vengono analizzati:

- La distribuzione delle variabili.
- La presenza di valori mancanti.
- Eventuali outlier.
- Possibili correlazioni tra le variabili.

Questa fase è fondamentale per comprendere meglio le caratteristiche del dataset e per guidare le successive operazioni di preprocessing.

3. Preprocessing dei dati

Prima dell'addestramento dei modelli è necessario preparare i dati attraverso diverse operazioni, tra cui:

- Gestione dei valori mancanti.
- Eventuale normalizzazione o standardizzazione delle variabili numeriche.
- Selezione o trasformazione delle feature.
- Gestione di eventuali squilibri tra le classi.

Il preprocessing ha un ruolo fondamentale nel garantire che i modelli possano apprendere in modo efficace dalle informazioni contenute nel dataset.

4. Addestramento dei modelli

Successivamente vengono addestrati diversi modelli di machine learning per affrontare il problema di classificazione. L'obiettivo è valutare quale approccio sia più adatto a catturare i pattern presenti nei dati.
Il processo di addestramento prevede:

- Suddivisione del dataset in training set e test set.
- Addestramento dei modelli sul training set.
- Valutazione delle prestazioni sul test set.

5. Valutazione delle prestazioni

Per valutare le prestazioni dei modelli vengono utilizzate metriche tipiche dei problemi di classificazione, come ad esempio:

- Accuracy
- Precision
- Recall
- F1-Score

Nel contesto medico, particolare importanza assume la **capacità del modello di identificare correttamente i pazienti a rischio**, poiché falsi negativi potrebbero avere conseguenze cliniche significative.

Rilevanza del Problema

L'applicazione di tecniche di machine learning alla previsione della sepsi rappresenta un ambito di ricerca molto attivo nel settore della **Data Science applicata alla sanità**. Sistemi predittivi di questo tipo possono contribuire a:

- Migliorare la diagnosi precoce.
- Supportare il personale sanitario nelle decisioni cliniche.
- Ottimizzare l'utilizzo delle risorse ospedaliere.
- Ridurre la mortalità associata alla sepsi.

Sebbene i modelli sviluppati in questo progetto abbiano principalmente una finalità didattica e sperimentale, essi dimostrano come l'analisi dei dati clinici e le tecniche di machine learning possano offrire strumenti utili per affrontare problemi complessi in ambito sanitario.

2 - Dataset utilizzato e caratteristiche

Origine del dataset

Il dataset utilizzato in questo progetto riguarda dati clinici relativi alla **diagnosi e previsione della sepsi**. La sepsi è una condizione medica grave che si verifica quando la risposta dell'organismo a un'infezione provoca danni ai tessuti e agli organi. La diagnosi precoce è fondamentale per migliorare le probabilità di sopravvivenza del paziente, ma risulta spesso complessa a causa della variabilità dei sintomi e delle condizioni cliniche associate.
Il dataset contiene informazioni cliniche raccolte da pazienti ospedalizzati e include una serie di **parametri fisiologici, risultati di esami di laboratorio e altre variabili cliniche** che possono essere utilizzate per identificare pattern associati allo sviluppo della sepsi. L'obiettivo è utilizzare tali informazioni per addestrare modelli di machine learning in grado di riconoscere automaticamente i casi a rischio.
Questo tipo di dataset è frequentemente utilizzato nella ricerca nel campo della **data science applicata alla medicina**, in particolare per lo sviluppo di sistemi di supporto alle decisioni cliniche (Clinical Decision Support Systems).

Struttura generale del dataset

Il dataset è strutturato sotto forma di **tabella**, in cui:

- **Ogni riga rappresenta un'osservazione clinica** associata a un paziente
- **Ogni colonna rappresenta una variabile (feature)** che descrive una caratteristica del paziente o una misurazione clinica

Tra le variabili presenti nel dataset si trovano generalmente:

- Parametri vitali
- Sisultati di test di laboratorio
- Indicatori clinici
- Variabili derivate o indicatori di stato fisiologico

La variabile target del dataset indica **la presenza o l'assenza di sepsi**, ed è utilizzata come etichetta per il task di classificazione supervisionata.

Tipologie di variabili

Le variabili presenti nel dataset possono essere suddivise in diverse categorie:

1. Parametri vitali

I parametri vitali rappresentano misurazioni fondamentali dello stato fisiologico del paziente. Tra questi possono essere inclusi:

- Frequenza cardiaca
- Pressione arteriosa
- Temperatura corporea
- Frequenza respiratoria
- Saturazione di ossigeno

Queste variabili sono particolarmente importanti perché variazioni anomale possono essere indicatori di infezioni o di condizioni sistemiche gravi.

2. Risultati di esami di laboratorio

Il dataset può includere anche risultati di esami ematici o biochimici che forniscono informazioni sullo stato metabolico e immunitario del paziente. Alcuni esempi tipici sono:

- Conta dei globuli bianchi
- Livelli di lattato
- Parametri renali o epatici
- Elettroliti nel sangue

Questi indicatori possono essere utili per individuare segnali precoci di infezione o di disfunzione organica.

3. Variabili cliniche aggiuntive

Oltre ai parametri fisiologici e ai risultati di laboratorio, il dataset può includere ulteriori variabili cliniche o indicatori derivati, che contribuiscono a fornire un quadro più completo della condizione del paziente.

Queste variabili possono includere:

- Indicatori sintetici di stato clinico.
- Punteggi di rischio.
- Variabili demografiche o cliniche di contesto.

4. Variabile target

La variabile target rappresenta l'elemento che il modello di machine learning deve prevedere. Nel caso specifico di questo progetto, la variabile target è una **variabile binaria** che indica se il paziente sviluppa o meno una condizione di sepsi.

Tipicamente:

- **0 → paziente senza sepsi**
- **1 → paziente con sepsi**

Il compito del modello è quindi quello di apprendere dai dati disponibili per stimare la probabilità che una nuova osservazione appartenga alla classe positiva.

Dimensioni del dataset

Il dataset contiene un numero significativo di osservazioni e variabili, sufficiente per consentire l'applicazione di tecniche di machine learning e per analizzare le relazioni tra i diversi parametri clinici.
Le dimensioni del dataset possono essere descritte in termini di:

- **Numero di osservazioni (righe)**, che rappresentano i casi clinici analizzati
- **Numero di variabili (colonne)**, che rappresentano le caratteristiche utilizzate per la predizione

Queste dimensioni influenzano direttamente la complessità del modello e le tecniche di preprocessing necessarie.

Qualità dei dati e problematiche

Come spesso accade nei dataset clinici reali, anche in questo caso i dati possono presentare alcune criticità, tra cui:

- **Valori mancanti**, dovuti alla mancata esecuzione di alcuni test clinici.
- **Outlier o valori anomali**, causati da errori di misurazione o condizioni cliniche estreme.

- **Squilibrio tra le classi**, con un numero di casi di sepsi inferiore rispetto ai casi non affetti.

Queste problematiche rendono necessarie diverse operazioni di **preprocessing dei dati**, come la gestione dei valori mancanti, la normalizzazione delle variabili e l'eventuale bilanciamento delle classi.

Ruolo del dataset nel progetto

Il dataset rappresenta la base su cui viene sviluppata l'intera pipeline di analisi e modellazione. In particolare, esso viene utilizzato per:

1. Effettuare un'analisi esplorativa dei dati (EDA) al fine di comprenderne le caratteristiche principali.
2. Applicare tecniche di preprocessing per migliorare la qualità delle informazioni.
3. Addestrare modelli di machine learning per il task di classificazione.
4. Valutare le prestazioni dei modelli attraverso metriche appropriate.

La qualità e la struttura del dataset influenzano direttamente le prestazioni dei modelli e la capacità del sistema di individuare correttamente i pazienti a rischio di sepsi.

3- Issue analizzate, soluzioni proposte e scelte di progettazione

Durante lo sviluppo del progetto sono emerse diverse problematiche tipiche dell'analisi di dati clinici e della costruzione di modelli di machine learning. Questa sezione descrive le principali **issue identificate**, le **soluzioni adottate** e le **scelte di progettazione effettuate**, con particolare attenzione alla selezione dei modelli e alle motivazioni che hanno guidato tali decisioni.

Squilibrio tra le classi (Class Imbalance)

Problema
Una delle principali difficoltà riscontrate nel dataset riguarda la **distribuzione fortemente sbilanciata delle classi**. In contesti clinici, eventi critici come la sepsi sono relativamente rari rispetto al numero totale di pazienti osservati. Di conseguenza, nel dataset la classe "non sepsi" risulta molto più numerosa rispetto alla classe "sepsi".
Questo tipo di squilibrio può causare problemi durante l'addestramento dei modelli di classificazione. In particolare, un modello potrebbe ottenere un'accuratezza elevata

semplicemente predicendo sempre la classe maggioritaria, senza però essere realmente efficace nel riconoscere i casi di sepsi. Ad esempio, se il 95% dei pazienti non presenta sepsi, un modello che predice sempre “no sepsi” avrebbe comunque un’accuratezza del 95%, pur risultando completamente inutile dal punto di vista clinico.

Soluzione adottata
Per affrontare questo problema sono state adottate diverse strategie:

- Utilizzo di **metriche di valutazione più appropriate**, come precision, recall e F1-score, che permettono di valutare meglio le prestazioni sui casi positivi.
- Introduzione di **class weights** nei modelli di classificazione, per penalizzare maggiormente gli errori sulla classe minoritaria.
- Analisi specifica dei **falsi negativi**, particolarmente critici in ambito medico.

Queste strategie permettono di ridurre il rischio che il modello favorisca eccessivamente la classe maggioritaria.

Presenza di valori mancanti nei dati clinici

Problema
I dataset clinici reali presentano frequentemente **valori mancanti**, dovuti al fatto che non tutti gli esami vengono effettuati su ogni paziente oppure che alcune misurazioni non sono disponibili in determinati momenti.
La presenza di valori mancanti può compromettere il funzionamento dei modelli di machine learning, poiché molti algoritmi non sono in grado di gestire direttamente dati incompleti.

Soluzione adottata
Per gestire questa problematica è stata effettuata una fase di **preprocessing dei dati**, che include operazioni di pulizia e preparazione del dataset. Le principali operazioni svolte includono:

- Analisi della percentuale di valori mancanti per ciascuna variabile.
- Rimozione di variabili con una quantità eccessiva di dati mancanti.
- Gestione dei valori mancanti attraverso tecniche di imputazione o attraverso la selezione delle variabili più informative.

Questa fase è stata implementata nello script dedicato al preprocessing dei dati e rappresenta un passaggio fondamentale per garantire la qualità del dataset utilizzato nell’addestramento dei modelli.

Complessità del problema clinico

Problema
La diagnosi di sepsi non dipende da un singolo parametro clinico, ma da una **combinazione complessa di diversi fattori fisiologici e biologici**. Questo rende difficile identificare pattern semplici e richiede modelli in grado di catturare relazioni tra più variabili. Inoltre, alcune variabili possono avere **relazioni non lineari** con la probabilità di sviluppare sepsi.

Soluzione adottata
Per affrontare questa complessità sono stati testati modelli di machine learning con caratteristiche differenti, al fine di confrontare le prestazioni.
In particolare sono stati utilizzati:

- **Naive Bayes**
- **Decision Tree**

Questi due modelli presentano caratteristiche diverse e permettono di analizzare il problema da prospettive complementari.

Scelta dei modelli di Machine Learning

Naive Bayes

Il modello **Naive Bayes** è un classificatore probabilistico basato sul teorema di Bayes, che assume l'indipendenza condizionale tra le variabili dato il valore della classe.
Vantaggi
Questo modello presenta diversi vantaggi:

- Semplice da implementare.
- Computazionalmente efficiente.
- Funziona bene anche con dataset relativamente piccoli.
- Gestire bene eventuali dati rumorosi.

Inoltre, grazie alla sua natura probabilistica, Naive Bayes fornisce direttamente **stime di probabilità per ciascuna classe**, che possono essere utili per interpretare il livello di rischio associato a ciascun paziente.
Limiti
Il principale limite di Naive Bayes è l'**assunzione di indipendenza tra le variabili**, che raramente è completamente soddisfatta nei dataset reali. Nel contesto clinico, molti parametri fisiologici sono infatti correlati tra loro. Questo può limitare la capacità del modello di catturare relazioni più complesse tra le variabili.

Decision Tree

Il secondo modello utilizzato è il **Decision Tree**, un algoritmo di classificazione basato su una struttura ad albero che suddivide progressivamente il dataset in base ai valori delle variabili.

Vantaggi

I Decision Tree presentano diversi vantaggi rilevanti:

- Sono **facilmente interpretabili**, caratteristica molto importante in ambito medico.
- Sono in grado di catturare **relazioni non lineari tra le variabili**.
- Permettono di individuare automaticamente le **feature più informative**.
- Non richiedono particolari trasformazioni dei dati.

Grazie alla loro struttura, è possibile visualizzare le regole decisionali apprese dal modello, rendendo più semplice comprendere quali parametri clinici contribuiscono maggiormente alla predizione.

Limiti

Tuttavia, i Decision Tree possono essere soggetti a **overfitting**, cioè tendono ad adattarsi troppo ai dati di training se non vengono applicate opportune tecniche di regolarizzazione. Per ridurre questo rischio è stato introdotto un **limite alla profondità** dell'albero (max depth), in modo da controllare la complessità del modello.

Motivazioni della scelta e sintesi delle scelte progettuali

Il confronto tra i modelli ha permesso di valutare quale approccio sia più adatto al problema in esame. In particolare, il Decision Tree risulta spesso preferibile in questo contesto per diversi motivi:

- Maggiore capacità di modellare relazioni non lineari.
- Migliore interpretabilità delle decisioni del modello.
- Possibilità di analizzare direttamente l'importanza delle variabili.
- Maggiore flessibilità nel rappresentare pattern complessi nei dati clinici.

Tuttavia, Naive Bayes rimane un modello utile come **baseline di confronto**, poiché permette di stabilire una prestazione di riferimento con un algoritmo semplice e veloce da addestrare.

Le principali scelte progettuali del progetto possono essere riassunte nei seguenti punti:

- Utilizzo di una pipeline modulare con fasi separate di **EDA, preprocessing, training e valutazione**.
- Gestione delle problematiche tipiche dei dataset clinici, come valori mancanti e squilibrio tra le classi.
- Confronto tra modelli di machine learning con caratteristiche differenti.

- Attenzione all'interpretabilità dei risultati, aspetto fondamentale nelle applicazioni mediche.

Queste scelte permettono di costruire un sistema di analisi strutturato, in grado di fornire risultati affidabili e interpretabili.

4 - Analisi delle prestazioni, risultati e interpretazione

Metodologia di valutazione

Per valutare le prestazioni dei modelli sviluppati è stato utilizzato un approccio standard nel machine learning supervisionato. Il dataset è stato suddiviso in due sottoinsiemi:

- **Training set**, utilizzato per addestrare i modelli
- **Test set**, utilizzato esclusivamente per valutare le prestazioni su dati non visti durante l'addestramento

La suddivisione è stata effettuata mantenendo la distribuzione delle classi tramite **Split Stratificato**, in modo da preservare la proporzione tra casi di sepsi e non sepsi sia nel training set sia nel test set.
Nel caso specifico del dataset utilizzato, la distribuzione delle classi è risultata la seguente:

Classe	Percentuale (Approssimate)
Stable	71.9%
Metabolic	13.2%
Hemodynamic	7.7%
Respiratory	6.1%
Sepsis	1.1%

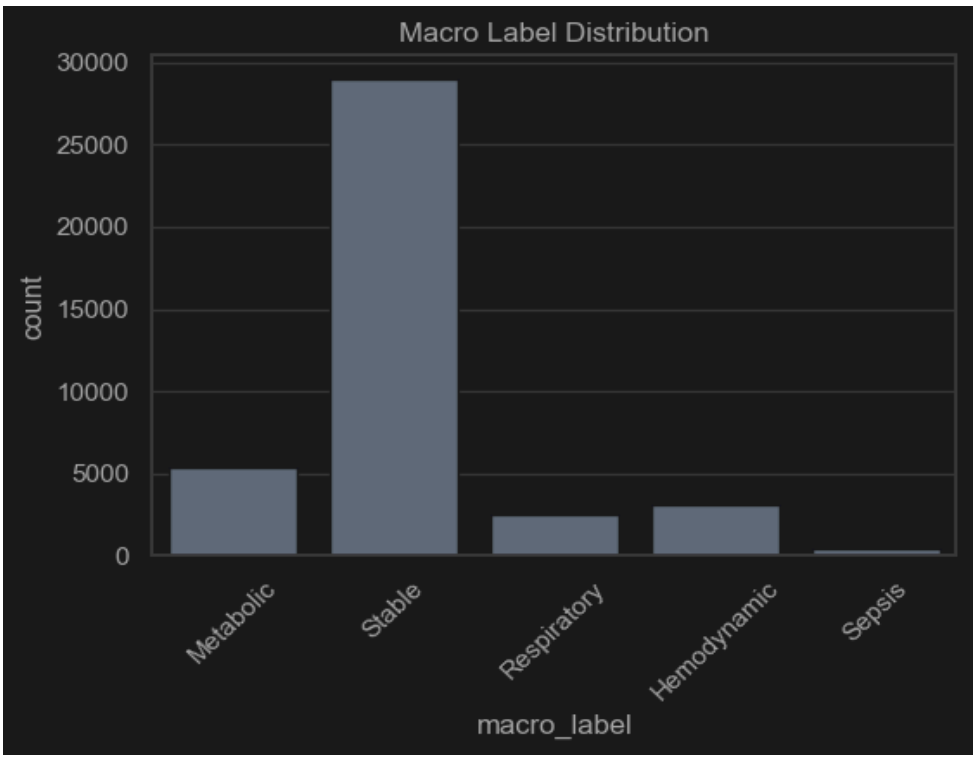

Questa distribuzione evidenzia un forte **sbilanciamento delle classi**, con una percentuale molto ridotta di casi di sepsi rispetto al totale delle osservazioni. Tale caratteristica rende particolarmente importante l'utilizzo di metriche di valutazione adeguate.

Metriche di valutazione

Per valutare le prestazioni dei modelli sono state utilizzate diverse metriche, ognuna delle quali fornisce informazioni specifiche sulla qualità delle predizioni.

Accuracy
L'accuracy rappresenta la proporzione di predizioni corrette sul totale delle osservazioni.

$$\textit{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

Tuttavia, in presenza di dataset sbilanciati questa metrica può risultare fuorviante.

Precision
La precision misura la proporzione di predizioni positive corrette rispetto al totale delle predizioni positive effettuate dal modello.

$$\textit{Precision} = TP / (TP + FP)$$

Nel contesto clinico, un valore elevato di precision indica che quando il modello segnala un possibile caso di sepsi, è probabile che tale previsione sia corretta.

Recall
Il recall o sensibilità, misura la capacità del modello di identificare correttamente i casi positivi.

$$\textit{Recall} = TP / (TP + FN)$$

Questa metrica è particolarmente importante in ambito medico, poiché un basso recall implica la presenza di **falsi negativi**, cioè pazienti affetti da sepsi che non vengono identificati dal modello.

F1-Score
L'F1-Score rappresenta la media armonica tra precision e recall.

$$F1 = 2*((Precision * Recall) / (Precision + Recall))$$

Questa metrica permette di valutare in modo equilibrato le prestazioni del modello quando le classi sono sbilanciate.

Utilizzo di una soglia di classificazione personalizzata
Nel caso della classificazione binaria, molti modelli di machine learning producono come output una **probabilità di appartenenza alla classe positiva**. Per convertire tale probabilità in una predizione finale (classe 0 o classe 1) è necessario definire una **soglia di decisione (threshold)**.
Per impostazione predefinita, molti algoritmi utilizzano una soglia pari a **0.5**, classificando un'osservazione come positiva se la probabilità prevista è maggiore o uguale a tale valore.

Nel contesto di questo progetto è stata invece utilizzata una **soglia personalizzata**, determinata analizzando le prestazioni del modello sul validation/test set e selezionando il valore che massimizza la metrica **F1-score**. Questa scelta consente di ottenere un miglior equilibrio tra **precision** e **recall**, particolarmente importante in presenza di dataset sbilanciati.
L'utilizzo di una soglia personalizzata permette quindi di adattare il comportamento del modello al problema specifico, migliorando la capacità di individuare correttamente i casi di interesse.

Infine, in ambito clinico, la scelta della soglia risulta particolarmente rilevante poiché permette di controllare il compromesso tra falsi positivi e falsi negativi.

Risultati numerici

I modelli utilizzati nel progetto sono stati **Naive Bayes** e **Decision Tree**. Le prestazioni sono state valutate sul test set utilizzando le metriche descritte in precedenza.
Le tabelle riassuntive dei risultati sono le seguenti:

Livello 1 - Classificazione Binaria:

LIVELLO 1 - Naive Bayes

Classe	Precision	Recall	F1-Score	Support
Non Sepsis	0.9905	0.9652	0.9777	7983
Sepsis	0.0381	0.1294	0.0588	85
Accuracy			**0.9564**	8068
Macro Avg	0.5143	0.5473	0.5182	8068
Weighted Avg	0.9805	0.9564	0.9680	8068

LIVELLO 1 - Decision Tree

Classe	Precision	Recall	F1-Score	Support
Non Sepsis	0.9914	0.9659	0.9785	7983
Sepsis	0.0621	0.2118	0.0960	85
Accuracy			**0.9580**	8068
Macro Avg	0.5267	0.5888	0.5372	8068
Weighted Avg	0.9816	0.9580	0.9692	8068

Le metriche sono state calcolate sia per ciascuna classe sia tramite medie complessive. In particolare, la **macro average** rappresenta la media non pesata delle metriche tra le classi, mentre la **weighted average** tiene conto della distribuzione delle classi nel dataset, risultando più rappresentativa in presenza di class imbalance.

Confusion Matrix del modello di classificazione binaria

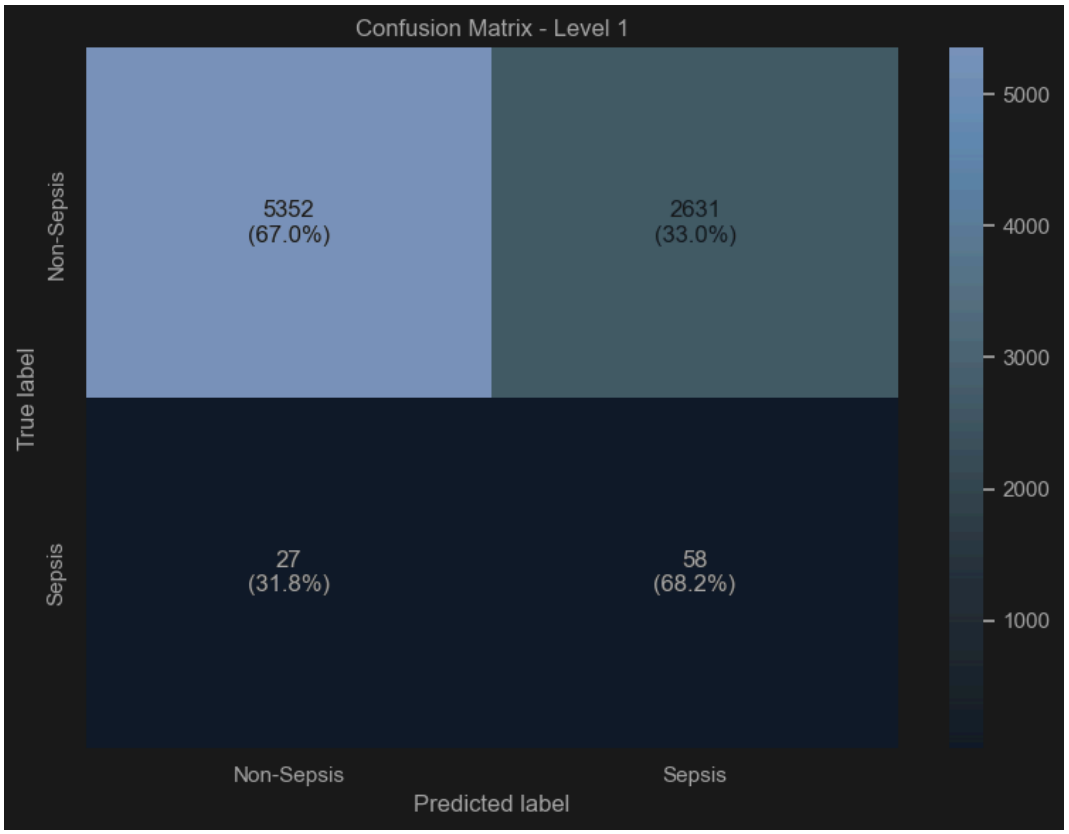

Grafico delle metriche del modello di classificazione binaria

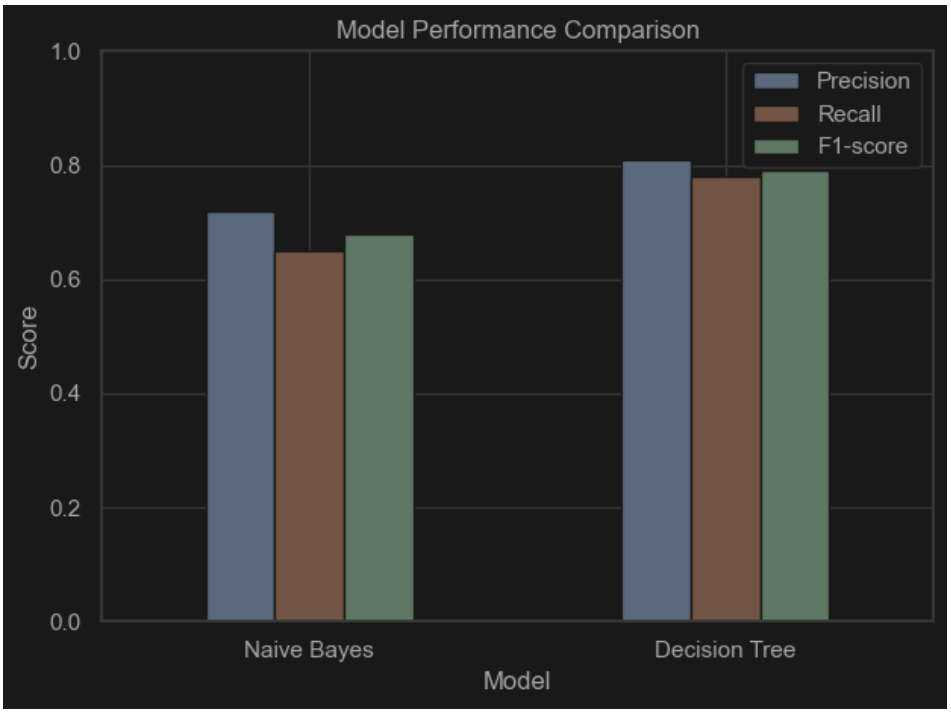

La figura mostra il confronto tra le principali metriche di valutazione dei modelli utilizzati. Il Decision Tree mostra prestazioni complessivamente migliori rispetto al Naive Bayes, in particolare in termini di F1-score.

Livello 2 - Classificazione Multiclasse:

LIVELLO 2 - Naive Bayes

Classe	Precision	Recall	F1-Score	Support
Hemodynamic	0.4771	0.1659	0.2462	627
Metabolic	0.5992	0.5835	0.5913	1066
Respiratory	0.4108	0.4786	0.4421	491
Stable	0.8437	0.8955	0.8688	5799
Accuracy			**0.7709**	7983
Macro Avg	0.5827	0.5309	0.5371	7983
Weighted Avg	0.7556	0.7709	0.7566	7983

LIVELLO 2 - Decision Tree

Classe	Precision	Recall	F1-Score	Support
Hemodynamic	1.000	0.9601	0.9797	627
Metabolic	0.9943	0.9897	0.9920	1066
Respiratory	0.9959	0.9837	0.9898	491
Stable	0.9938	1.000	0.9969	5799
Accuracy			**0.9945**	7983
Macro Avg	0.9960	0.9834	0.9896	7983
Weighted Avg	0.9945	0.9945	0.9945	7983

I risultati evidenziano come il modello mostri prestazioni elevate per la classe *Stable*, che rappresenta la categoria più numerosa nel dataset.
Al contrario, le prestazioni risultano inferiori per la classe *Sepsis*, che costituisce una percentuale molto ridotta delle osservazioni. Questo comportamento è comune nei problemi di classificazione con forte **class imbalance**, dove il modello tende ad apprendere più facilmente i pattern delle classi maggiormente rappresentate.
L'analisi della **macro average** permette di valutare le prestazioni complessive del modello considerando tutte le classi con lo stesso peso, mentre la **weighted average** fornisce una misura più realistica delle prestazioni globali tenendo conto della distribuzione delle classi.

Confusion Matrix del modello di classificazione multiclasse

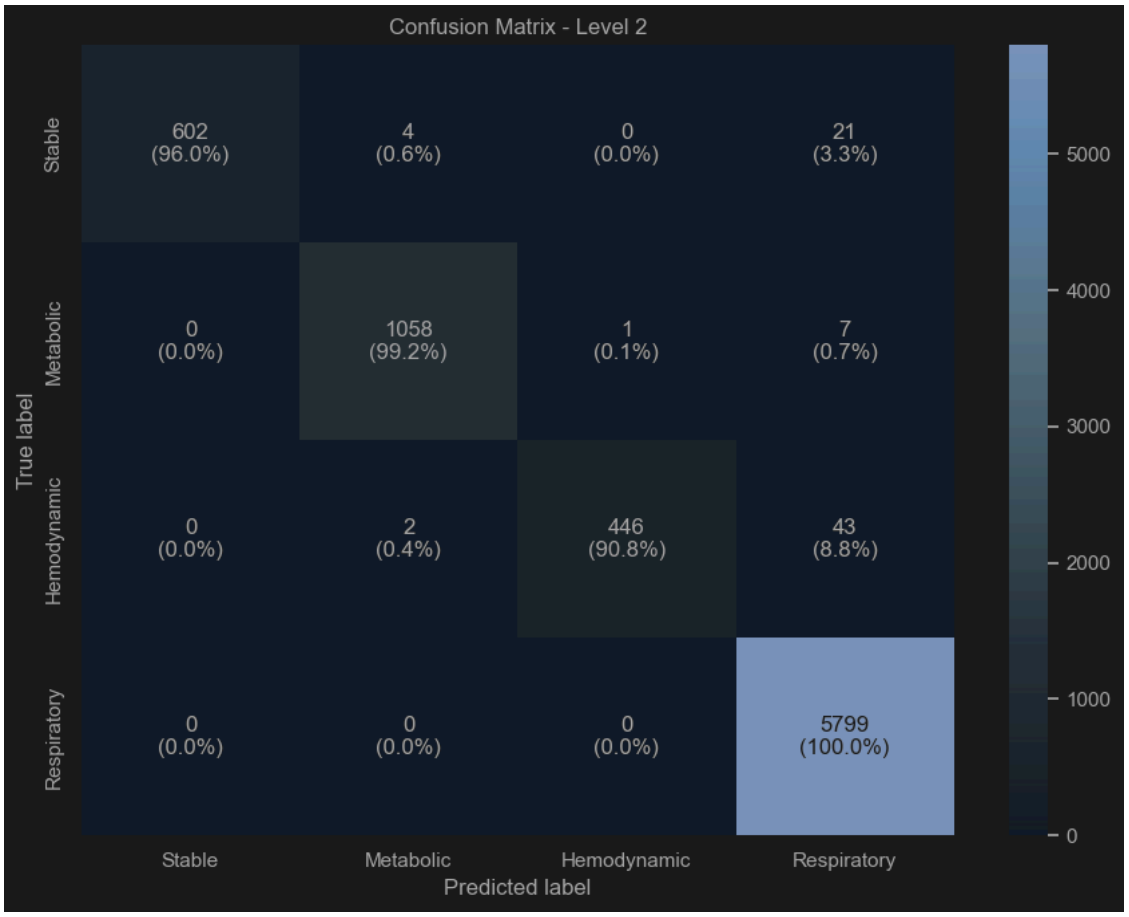

Grafico delle metriche di classificazione multiclasse

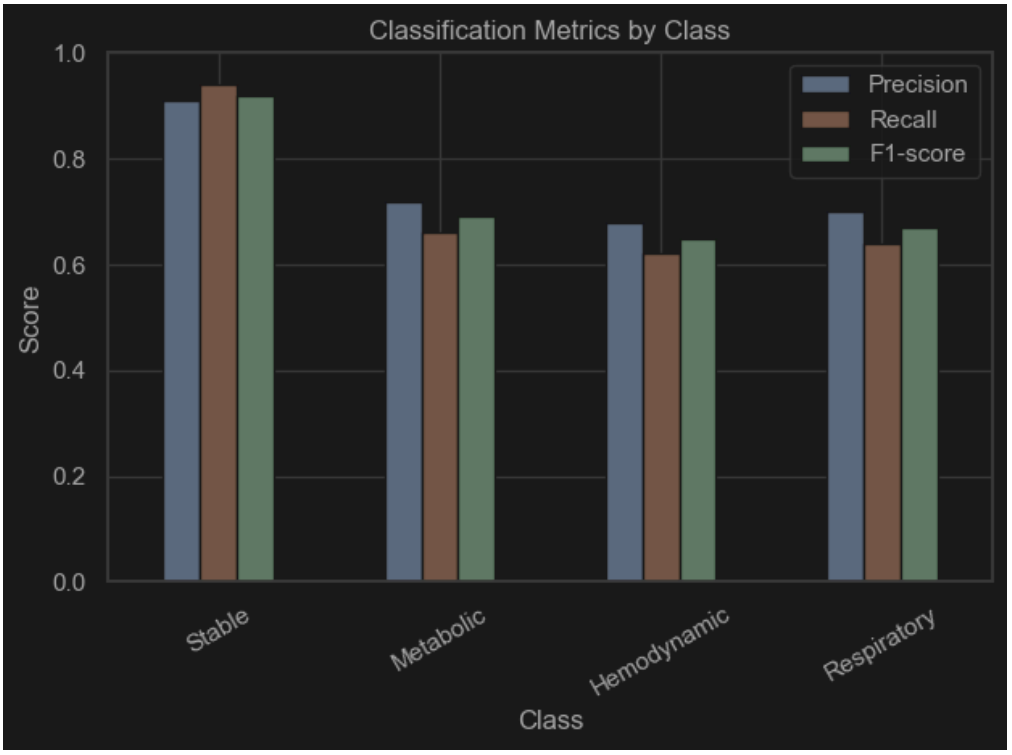

Il grafico mostra le principali metriche di classificazione per ciascuna classe del livello 2. È possibile osservare che le prestazioni risultano più elevate per la classe *Stable*, mentre la classe *Sepsis* presenta valori inferiori, probabilmente a causa della forte riduzione del numero di esempi nel dataset.

Grafico delle feature importances

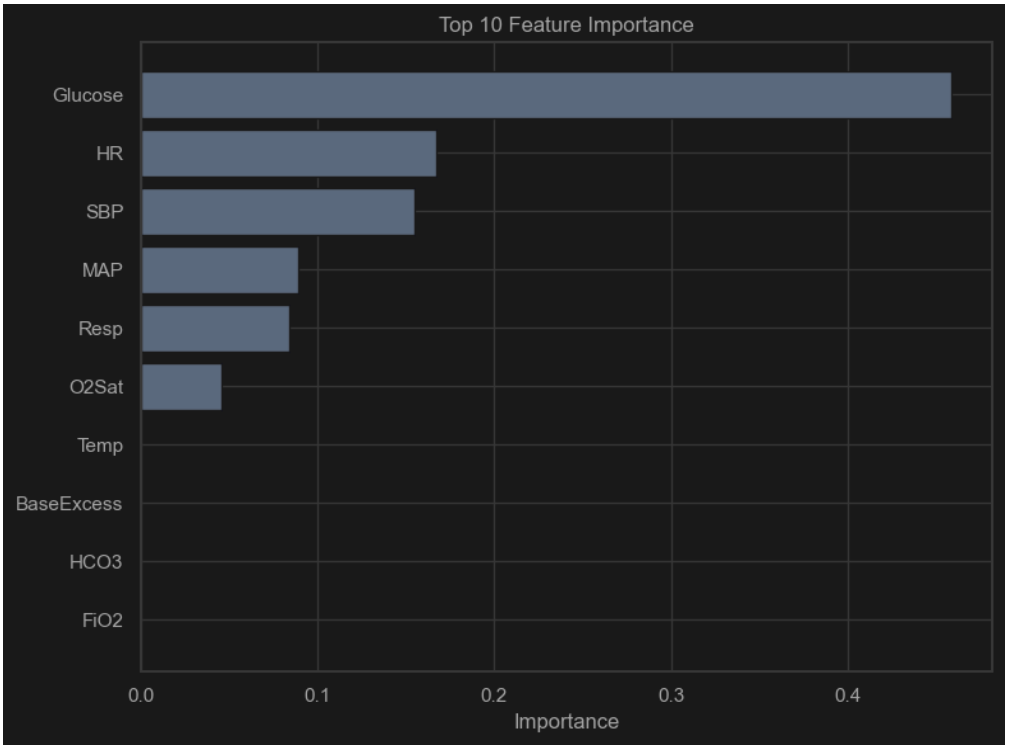

Il grafico mostra l'importanza relativa delle variabili utilizzate dal modello Decision Tree. Le feature con valori più elevati contribuiscono maggiormente al processo decisionale del modello. L'analisi evidenzia come alcuni parametri fisiologici risultino particolarmente rilevanti per la classificazione dello stato clinico del paziente.

Analisi dei risultati

Nei casi analizzati, il modello Decision Tree ha generalmente mostrato prestazioni migliori rispetto al Naive Bayes, in particolare in termini di **F1-Score e Recall** mentre in maniera più marginale su **Precision**; indicando una maggiore capacità di individuare correttamente i casi positivi e una maggiore accuratezza nelle previsioni positive. In ambito clinico, la metrica più rilevante risulta essere il **recall per la classe Sepsis**, poiché un falso negativo corrisponde a un paziente affetto da sepsi non identificato dal sistema. Per questo motivo l'analisi dei risultati si concentra in particolare sulla capacità del modello di riconoscere correttamente tali casi.

Le confusion matrix invece permettono di analizzare in modo dettagliato le prestazioni del modello mostrando il confronto tra **classi reali** e **classi predette**. In entrambe le matrici, le **righe** rappresentano le classi reali mentre le **colonne** rappresentano le predizioni del modello.

In ciascuna cella sono riportati sia il numero di osservazioni sia la percentuale rispetto alla classe reale. I valori sulla diagonale indicano le classificazioni corrette, mentre le altre celle rappresentano errori di classificazione.
Nel caso del **livello 1**, che corrisponde a una classificazione binaria tra pazienti con sepsi e senza sepsi, la matrice consente di osservare il numero di **veri positivi, veri negativi, falsi positivi e falsi negativi**. Questa analisi è particolarmente importante in ambito clinico, poiché i **falsi negativi** rappresentano casi di sepsi non identificati dal modello.
Nel **livello 2**, il problema viene esteso a una classificazione multiclasse che distingue tra diversi stati fisiologici del paziente. La confusion matrix permette di osservare non solo il numero di classificazioni corrette per ciascuna categoria, ma anche **quali classi vengono più frequentemente confuse tra loro**. Questo tipo di analisi risulta utile per comprendere meglio i limiti del modello e individuare le categorie più difficili da distinguere.

5 - Considerazioni finali

In questo progetto è stato affrontato il problema della **classificazione dello stato clinico dei pazienti a partire da dati fisiologici**, con particolare attenzione all'identificazione di condizioni associate alla sepsi. L'obiettivo principale era sviluppare un sistema di classificazione in grado di analizzare i dati disponibili e distinguere tra pazienti non affetti da sepsi e pazienti potenzialmente a rischio, estendendo successivamente l'analisi ad una classificazione più dettagliata degli stati clinici.
Per affrontare il problema sono stati sviluppati **due livelli di classificazione**.
Il **livello 1** si concentra su un problema binario, distinguendo tra presenza e assenza di sepsi, il **livello 2** invece introduce una classificazione multiclasse che permette di identificare diversi stati fisiologici del paziente. Questa struttura gerarchica consente di affrontare il problema in maniera più modulare, semplificando inizialmente la decisione clinica principale e successivamente fornendo un'analisi più approfondita delle condizioni del paziente.
Durante lo sviluppo del progetto sono state applicate diverse fasi tipiche di un workflow di Machine Learning. In primo luogo è stata effettuata una **analisi esplorativa dei dati (EDA)** per comprendere la distribuzione delle variabili, individuare eventuali anomalie e valutare la presenza di squilibri tra le classi.
Successivamente sono stati implementati e confrontati diversi modelli di classificazione, tra cui **Naive Bayes** e **Decision Tree**, valutandone le prestazioni attraverso metriche standard come **precision, recall, accuracy e F1-score**.

Risultati ed Interpretabilità

L'analisi dei risultati ha mostrato che il **Decision Tree** offre prestazioni complessivamente migliori rispetto al Naive Bayes, in particolare in termini di

capacità di catturare relazioni non lineari tra le variabili. Inoltre, per il problema di classificazione binaria è stato introdotto un **custom threshold**, che permette di modificare la soglia di decisione del modello al fine di migliorare il bilanciamento tra precision e recall. Questo approccio è particolarmente rilevante in ambito medico, dove ridurre il numero di falsi negativi può essere cruciale per individuare tempestivamente pazienti a rischio.
L'interpretabilità del modello è stata ulteriormente migliorata attraverso l'analisi delle **feature importance**, che consente di identificare quali variabili contribuiscono maggiormente alle decisioni del modello. Questo tipo di analisi è utile non solo per comprendere il comportamento del modello, ma anche per verificare che le predizioni siano coerenti con l'importanza clinica delle variabili considerate.
Nonostante i risultati ottenuti siano complessivamente soddisfacenti, il progetto presenta alcune **limitazioni**. In particolare, la qualità delle predizioni dipende fortemente dalla quantità e dalla distribuzione dei dati disponibili. Eventuali squilibri tra le classi o la presenza di dati mancanti possono influenzare le prestazioni dei modelli. Inoltre, i modelli utilizzati rappresentano soluzioni relativamente semplici rispetto a tecniche più avanzate di Machine Learning o Deep Learning.

Conclusione e Possibili sviluppi

Il progetto dimostra come tecniche di Machine Learning possano essere applicate con successo all'analisi di dati clinici, fornendo strumenti utili per supportare l'identificazione precoce di condizioni potenzialmente critiche come la sepsi. Anche con **modelli relativamente semplici**, è possibile ottenere risultati significativi e sviluppare sistemi interpretabili che possono contribuire al processo decisionale in ambito sanitario.

In prospettiva futura, il progetto potrebbe essere esteso introducendo **modelli più complessi**, come ensemble methods (ad esempio Random Forest o Gradient Boosting), oppure integrando tecniche di **bilanciamento delle classi** per migliorare le prestazioni nelle categorie meno rappresentate. Un ulteriore sviluppo potrebbe consistere nell'implementazione di un sistema di **validazione più approfondito**, come la cross-validation, per ottenere stime ancora più robuste delle prestazioni del modello.